

Proyecto 1 — Introducción a la Ciencia de los Datos

Fase A — Diseño de la Bodega de Datos (25%)

Dataset elegido	Siniestros Viales — Cali (Datos Abiertos Alcaldía de Cali)
Grupo	#5
Estudiantes	Juan Alejandro Urrego 2569068 Mariana De Los Ángeles Viera 2569104 Anderson Gómez 2266242 Juan Esteban Martinez Orobio 2569452
Fecha	15 de septiembre de 2026

1. Selección del dataset

Dataset elegido: Siniestros Viales — Cali.

Para la selección se evaluaron tres conjuntos de datos de la Secretaría de Movilidad de Cali: *Siniestralidad* (~90.000 registros, 2016-2024), *Lesionados en accidentes de tránsito* (~51.000 registros, 2016-2025) y *Consolidado de muertes en accidentes de tránsito* (~2.400 registros, 2016-2023). Se eligió el primero porque ofrece el mejor equilibrio entre las cuatro fases del proyecto.

Viabilidad técnica. Su volumen (~90.000 registros) es manejable para un pipeline ETL construido en un computador personal. Está muy por encima del mínimo de 1.000 registros exigido, pero lejos de los volúmenes de millones de otras opciones del catálogo. Se descarga en formato CSV desde el portal de Datos Abiertos de la Alcaldía de Cali sin necesidad de autenticación, cumpliendo el criterio de descarga directa. No está incluido en la lista de datasets bloqueados del catálogo.

Estructura apta para un modelo estrella. Sus variables clave (fecha, comuna, barrio, tipo de vía, gravedad, actor vial, género, edad y condición del actor) se agrupan de forma natural en dimensiones diferenciadas: cuándo, dónde, en qué tipo de vía y quién estuvo involucrado. Esto permite construir un modelo estrella genuino sin forzar relaciones artificiales entre los datos.

Variable objetivo definida. La gravedad del siniestro está bien definida y es directamente utilizable en un problema de clasificación, cumpliendo el criterio de contar con al menos una variable objetivo clara.

Facilidad para las fases posteriores. Al tratarse de un tema de seguridad vial urbana, facilita la formulación de preguntas de negocio concretas y visualizaciones intuitivas en las Fases C y D.

Por qué no se seleccionaron los otros dos datasets.

Lesionados en accidentes de tránsito (~51.000 registros).

- No incluye comuna, barrio, género ni edad. Solo trae la dirección en texto libre y cuatro indicadores del tipo de actor (automóvil, moto, ciclista y peatón). Con esto no se pueden construir las dimensiones de lugar y de perfil de actor definidas en el modelo.
- No contiene un identificador de siniestro, lo que impide agrupar registros del mismo evento o detectar duplicados.
- Registra únicamente personas lesionadas, así que no incluye los siniestros sin lesionados ni a los fallecidos. Por eso no sirve como base para clasificar la gravedad (leve, grave, mortal).

Consolidado de muertes en accidentes de tránsito (~2.400 registros).

- Todos sus registros son víctimas fatales, de modo que no hay variación en la variable de interés y no se puede plantear un problema de clasificación de gravedad.
- No contiene ubicación (comuna, barrio o dirección) ni tipo de vía, por lo que no permite análisis geográficos como la segmentación de barrios por riesgo.
- Su volumen es muy inferior al mínimo útil para entrenar modelos y su cobertura termina en 2023, un año antes que siniestralidad.

Por qué no se cruzaron los tres datasets.

- **Sin llave común.** Solo siniestralidad cuenta con un identificador de siniestro. Unir los demás por fecha, hora y dirección generaría falsos emparejamientos y pérdida de registros, ya que la dirección está en texto libre y puede haber varios siniestros en la misma fecha y hora.
- **Información redundante.** Siniestralidad ya incluye la condición del actor (ileso, herido o fallecido), así que lesionados y muertes describen subconjuntos de lo que este dataset ya contiene.


Lesionados y muertes se conservan como **fuentes de validación externa** (comparar tendencias anuales con los totales de siniestralidad) y como posible ampliación en trabajos futuros.

2. Tipo de modelo dimensional

Se adopta un modelo en estrella la tabla de hechos **FACT_SINIESTRO** se conecta directamente con cada una de las cuatro tablas de dimensión (**DIM_TIEMPO**, **DIM_LUGAR**, **DIM_VIA**, **DIM_ACTOR**), sin niveles adicionales de normalización.

Se descarta el modelo copo de nieve por tres razones. Primero, el volumen de datos (~90.000 hechos) no justifica el ahorro de espacio que traería normalizar las dimensiones; ese ahorro solo se nota con volúmenes mucho mayores. Segundo, ninguna dimensión tiene una jerarquía tan profunda como para merecer tablas separadas por nivel: por ejemplo, comuna y barrio conviven bien como columnas de una misma tabla **DIM_LUGAR**, en vez de partarlos en **DIM_COMUNA** y **DIM_BARRIO** relacionadas entre sí. Tercero, el modelo estrella simplifica las consultas SQL analíticas que se construirán en la Fase C (menos JOINS, sentencias más cortas y legibles) y facilita el modelado directo de las visualizaciones de la Fase D, que es justamente el propósito de una bodega orientada a análisis descriptivo y no a transacciones.

3. Diagrama de la bodega



El diagrama muestra el modelo estrella: la tabla de hechos **fact_siniestro** en el centro, conectada mediante llaves subrogadas (**sk_***) a las cuatro dimensiones, con cardinalidad 1 a N desde cada dimensión hacia el hecho.

Grano del hecho: una fila de **fact_siniestro** representa un actor vial involucrado en un siniestro ocurrido en una fecha, un lugar y un tipo de vía específicos (no "un siniestro", ya que un mismo siniestro puede tener varios actores). La columna **id_siniestro** permite, si se necesita, reagrupar los actores de un mismo evento.

4. Tabla de hechos – **FACT_SINIESTRO**

Columna	Tipo	Rol	Descripción
sk_fact_siniestro	bigint	PK	Llave subrogada autoincremental.
fk_tiempo	int	FK	Referencia a DIM_TIEMPO.
fk_lugar	int	FK	Referencia a DIM_LUGAR.
fk_via	int	FK	Referencia a DIM_VIA.
fk_actor	int	FK	Referencia a DIM_ACTOR.
id_siniestro	varchar	Degenerada	Identificador del siniestro en la fuente original; agrupa los actores de un mismo evento.
gravedad_siniestro	varchar	Atributo/medida	leve / grave / mortal - variable objetivo de clasificación.
condicion_resultado	varchar	Atributo/medida	Resultado del actor: ileso / herido / fallecido.
edad_actor	int	Medida semiaditiva	Edad exacta reportada; se agrega con AVG, no con SUM.

cantidad_siniestros	int	Medida aditiva	Siempre 1; permite conteos agregando con SUM.
es_fatal	int (0/1)	Medida aditiva	Bandera para sumar fácilmente actores fallecidos.

Gravedad y condición se dejan como columnas de **fact_siniestro** en lugar de convertirlas en una dimensión propia porque no describen un "tipo" de entidad reutilizable como sí lo hacen barrio, tipo de vía o tipo de actor, sino el **resultado** de ese siniestro en particular: cambian fila por fila y no tienen atributos adicionales que las acompañen. Además, son justamente la variable objetivo del proyecto (la que se va a clasificar en la Fase C), así que conviene tenerlas accesibles directamente en el hecho, sin pasar por un JOIN extra solo para consultar 3 o 4 valores fijos. Crear una **dim_gravedad** aparte sería válido, pero sería sobre-diseño para algo tan simple; ese patrón (juntar varios indicadores pequeños en una dimensión) solo se justifica cuando hay varios flags relacionados, no para un solo campo de pocos valores.

5. Tablas de dimensión – justificación

DIM_TIEMPO

Por qué existe: casi todas las preguntas de negocio del proyecto implican analizar los siniestros a través del tiempo (tendencias, estacionalidad, patrones por día de la semana). Separar el tiempo en su propia dimensión evita recalcular mes, trimestre o día de la semana en cada consulta y es indispensable para las visualizaciones de serie de tiempo de la Fase D.

Granularidad: una fila por cada fecha calendario distinta presente en los siniestros (grano diario).

Atributos: fecha, año, mes, nombre_mes, trimestre, día_semana, es_fin_de_semana.

DIM_LUGAR

Por qué existe: la ubicación (comuna, barrio) es el eje geográfico de la mayoría de objetivos analíticos del proyecto ("predecir por comuna", "segmentar barrios por riesgo"). Aislarla en una dimensión evita repetir texto de comuna/barrio en cada fila del hecho y da un catálogo único de ubicaciones.

Granularidad: una fila por cada combinación única de comuna y barrio.

Atributos: comuna, barrio, ciudad, zona (urbana/rural).

DIM_VIA

Por qué existe: el tipo de vía condiciona directamente el riesgo y la gravedad de un siniestro (no es lo mismo una vía arterial que una calle local). Modelarla aparte permite comparar siniestralidad por tipo de infraestructura sin mezclarla con la ubicación geográfica.

Granularidad: una fila por cada combinación única de tipo de vía, clase y superficie.

Atributos: tipo_via, clase_via, superficie.

DIM_ACTOR

Por qué existe: las preguntas de clasificación y segmentación dependen fuertemente de quién estuvo involucrado (peatón, ciclista, motociclista, conductor), su género y su rango de edad. Separarlo evita repetir combinaciones de texto y crea un catálogo reutilizable de perfiles de actor.

Granularidad: una fila por cada combinación única de tipo de actor vial, género y rango de edad (es un "perfil", no una persona individual).

Atributos: tipo_actor_vial, género, rango_edad.

6. Trazabilidad con los objetivos analíticos del catálogo

Objetivo del catálogo	Cómo lo resuelve el modelo
Clasificar gravedad (leve/grave/mortal)	gravedad_siniestro en FACT_SINIESTRO, con las 4 dimensiones (tiempo, lugar, vía, actor) como variables explicativas.
Predecir probabilidad de accidente por comuna-hora	JOIN de FACT_SINIESTRO con DIM_LUGAR (comuna) y DIM_TIEMPO (fecha/día); si se confirma un campo de hora en la fuente real, se agrega a DIM_TIEMPO en la Fase B.
Segmentar barrios por perfil de riesgo	GROUP BY sobre DIM_LUGAR.barrio, agregando cantidad_siniestros y es_fatal desde el hecho.

7. Supuestos y validaciones pendientes para la Fase B

El catálogo del curso confirma las variables clave usadas en este diseño (fecha, comuna, barrio, tipo de vía, gravedad, actor vial, género, edad, condición del actor), pero no detalla el diccionario completo de columnas del CSV real. Antes de construir el pipeline ETL, el equipo debe:

- Descargar el CSV desde el portal de Datos Abiertos de la Alcaldía de Cali y confirmar los nombres exactos de columnas, su codificación de texto y los valores nulos.
- Verificar si existe un campo de hora/franja horaria explícito (el catálogo menciona "comuna-hora" como posible objetivo); si no existe, evaluar si se puede derivar o si DIM_TIEMPO se queda en grano diario.
- Confirmar la disponibilidad real de clase_vía, superficie y zona; si alguno no está en la fuente, se documenta como "No disponible" y se ajusta la dimensión correspondiente sin afectar el resto del modelo.
- Definir las reglas de generación de las llaves subrogadas (sk_*) y el manejo de valores faltantes mediante un registro por defecto (-1 / "Desconocido") en cada dimensión.
- Validar duplicados de id_siniestro y decidir la regla de deduplicación antes de cargar a PostgreSQL.

