Fase A — Los 3 hallazgos más importantes del EDA

Siniestralidad vial de Santiago de Cali, 2016–2024 · Grupo #5 · Juan Alejandro Urrego (2569068) · Mariana De Los Ángeles Viera (2569104) · Anderson Gómez (2266242) · Juan Esteban Martinez Orobio (2569452) · Profesor: Héctor Fabio Ocampo Arbeláez · Octubre 2026

Contexto. La base contiene 371 003 reportes de incidentes viales recibidos por la Secretaría de Movilidad de Cali entre enero de 2016 y noviembre de 2024. Cada reporte indica si se confirmó un siniestro y con qué gravedad, la dirección, la clase de accidente, el medio de reporte y los vehículos involucrados. La pregunta de negocio es **qué características conocidas al momento del reporte permiten anticipar si un siniestro tendrá lesionados o fallecidos**, para priorizar ambulancias y orientar la prevención.

Continuidad con el Proyecto 1. Es el mismo dataset y el mismo caso de negocio del P1. El modelo estrella diseñado allí (FACT_SINIESTRO con DIM_TIEMPO, DIM_LUGAR, DIM_VIA y DIM_ACTOR) se reconstruyó con los datos reales en *fase_a_eda.ipynb* (sección 2.1). Se respetaron sus reglas (llaves subrogadas, registro −1 «Desconocido») y se adaptaron lugar y actor, porque el CSV no trae comuna, barrio, género ni edad. La gravedad *leve / grave / mortal* del P1 equivale a solo daños / con lesionado / con fallecido.

Hallazgo 1. Dos de cada tres reportes no son siniestros; los mortales no bajan

El 66 % de los reportes se confirma como *negativo*. Quedan 124 889 siniestros reales: 59 % de solo daños, 38 % con lesionados y 2,7 % con fallecidos (3 360 casos). En la nomenclatura del P1, los siniestros **mortales son estables** (362 a 451 por año entre 2016 y 2023), mientras los leves caen: el porcentaje mortal pasa de ≈2 % a 7,9 % en 2023. **Implicación:** la meta de reducir muertes no muestra avances, y la operación gasta una parte importante de su capacidad verificando incidentes que no lo son; un modelo que estime la gravedad desde el reporte ayudaría a decidir qué recurso enviar primero.

Hallazgo 2. El actor vial define la gravedad: moto y bicicleta frente a carro

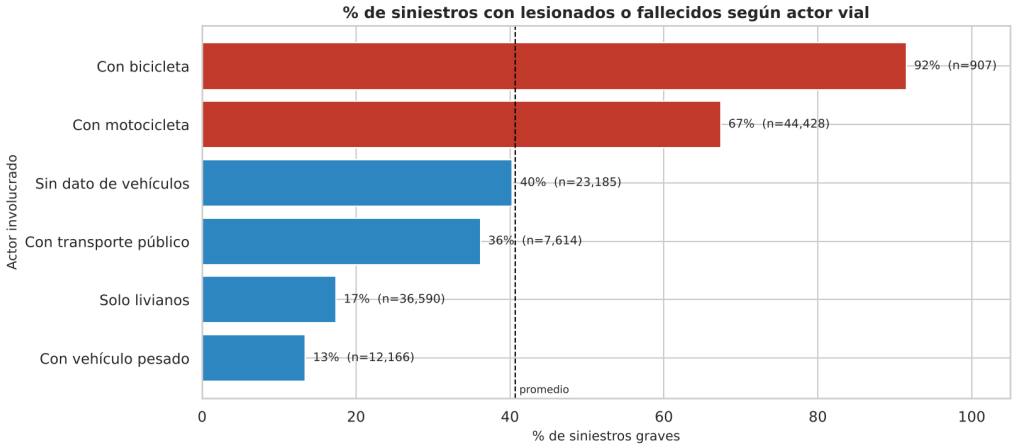


Figura 1. Proporción de siniestros graves según el actor vial más vulnerable involucrado.

Cuando participa una bicicleta, el 92 % de los siniestros es grave; con motocicleta, el 67 %; cuando solo hay vehículos livianos, apenas el 17 %. Es la relación más fuerte del dataset: la presencia de motos tiene correlación de Spearman +0,49 con la gravedad y el número de vehículos livianos −0,53. Además, los siniestros de un solo vehículo (atropellos, caídas, volcamientos) son el 21 % de los graves frente al 3 % de los de solo daños. **Implicación:** priorizar ambulancia cuando el reporte menciona moto

o bicicleta, y mantener las campañas de seguridad para motociclistas y ciclistas.

Hallazgo 3. El registro cambió: la base de 2023–2024 no es comparable

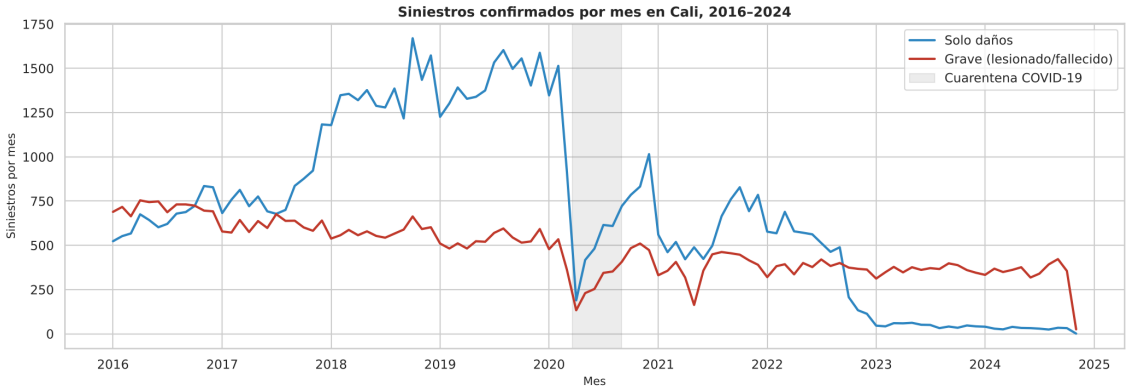


Figura 2. Siniestros confirmados por mes según gravedad.

Los siniestros graves bajan gradualmente (≈700/mes en 2016 a ≈370/mes en 2024), pero los de solo daños se duplican en 2018–2019 y luego casi desaparecen desde finales de 2022. Un salto tan brusco refleja un cambio de protocolo (choques simples resueltos con arreglo directo, sin reporte), no una mejora real. A esto se suma que la clase de accidente y el medio de reporte solo se diligencian de forma sistemática desde 2021 (78 % vacíos en total) y que la base usa un punto «.» en lugar de celdas vacías. **Implicación:** los indicadores de 2023–2024 deben leerse con cautela, la limpieza debe tratar el faltante como estructural y los modelos deben incluir el año.

Otros hallazgos de apoyo

- **Domingo** es el día de mayor gravedad (50 % de siniestros graves frente a ≈39 % entre semana), aunque los días hábiles concentran más volumen: operativos de velocidad y alcoholemia en fin de semana.
- **Puntos críticos:** el 10 % de las intersecciones con siniestros graves concentra el 46 % de ellos (encabezan Calle 70 con Carrera 8 y Calle 5 con Carrera 80).
- La variable *siniestros por dirección* tiene asimetría de 21: requiere transformación logarítmica en la Fase B.
- Objetivos del P1: *clasificar gravedad* → Fase C (binario y multiclase); *segmentar barrios* → segmentación de intersecciones (no hay barrio); *predecir por comuna-hora* → no es posible sin comuna ni hora; se usa día de la semana y mes.