Fase B — Pasos de limpieza y justificación de cada decisión

Siniestralidad vial de Cali 2016–2024 · Grupo #5 · Juan Alejandro Urrego (2569068) · Mariana De Los Ángeles Viera (2569104) · Anderson Gómez (2266242) · Juan Esteban Martinez Orobio (2569452) · Profesor: Héctor Fabio Ocampo Arbeláez · Octubre 2026

El pipeline completo está en *fase_b_limpieza.ipynb* y produce *datos_limpios.parquet* (124 889 filas × 54 columnas, 0 nulos). Variables objetivo: **es_grave** (1 = con lesionado o fallecido, 0 = solo daños) y **gravedad_p1** (leve / grave / mortal, la variable objetivo definida en el Proyecto 1, con codificación ordinal 0-1-2). Este notebook cumple el papel del ETL previsto en el P1.

0. Validaciones pendientes del Proyecto 1 (sección 7 del diseño de la bodega)

Validación pendiente en el P1	Resultado con el CSV real	Decisión
Nombres de columnas, codificación y nulos	10 columnas (2 repetidas); cp1252; separador «;»; nulos escritos como «.»	Lectura con cp1252, renombrado y «.» → nulo
¿Existe hora o franja horaria?	No, solo fecha	DIM_TIEMPO en grano diario; «comuna-hora» se reemplaza por día y mes
¿Existen clase_via, superficie, zona?	No; tampoco comuna, barrio, género ni edad	Se documentan como «No disponible»; tipo_via sale de la dirección
Registro por defecto −1 / «Desconocido»	Faltantes estructurales en clase (78 %), medio (78 %) y dirección (56 %)	Misma regla: categoría SIN_DATO + indicadores de faltante
Duplicados de id_siniestro	4 códigos repetidos, todos duplicados exactos	Una fila por código (drop_duplicates)

1. Diagnóstico

- **Nulos disfrazados:** la base usa «.» como vacío. clase_accidente 88 %, medio_reporte 78 %, vehiculos_implicados 60 %, num_vehiculos 52 %, dirección 50 % (sobre el total de reportes).
- **Duplicados:** 4 filas idénticas (códigos 350723, 354438, 361442, 361474) y una fila vacía al final del archivo. Se eliminan porque contarían dos veces el mismo hecho.
- **Texto inconsistente:** CHOQUE/Choque, NO APLICA/NOAPLICA, Solo daños/Solo Daños, TELEF?NICO 127/TELEF?NICO127, caracteres corruptos por la codificación cp1252 y dos observaciones de texto libre dentro de medio_reporte. Se normaliza a mayúsculas sin tildes y se unifican sinónimos; categorías con menos de 300 casos se agrupan en OTRO.
- **Columnas:** clase_accidente está duplicada (idéntica en el 99,9997 %): se elimina la copia. **detalle_confirmado se elimina por fuga de información**: contiene textos como «Choque con Lesionados» o «Muerto en la vía», escritos después de conocer la gravedad.

2. Alcance y partición

Se modelan solo los siniestros confirmados (los reportes negativos no tienen gravedad). **Antes de imputar o escalar** se hace la partición estratificada 80/20 (99 911 train / 24 978 test, semilla 42) y se guarda en la columna *particion*. Todos los estadísticos (mediana, moda, vecinos KNN, límites de outliers, escaladores) se calculan solo con train: así no hay fuga de información hacia el conjunto de prueba.

3. Valores nulos: estrategia por columna

Columna	% nulos	Estrategia	Por qué
num_vehiculos	4,3 %	Deducción desde la lista + **mediana** (2)	Discreta y sesgada: la mediana es robusta y es un valor real; la media (1,96) no es un número de vehículos posible.
n_motos, n_livianos, n_pesados, n_transporte_publico, n_bicicletas	18,6 %	**KNN (k=5, ponderado por distancia)** + indicador vehiculos_sin_dato	Están correlacionadas con num_vehiculos, la clase de accidente y el lugar; KNN aprovecha esa estructura. El indicador conserva que el faltante es informativo (40 % graves).
medio_reporte	78 %	**Moda por año** (2021–2024) + categoría SIN_DATO (2016–2020)	Antes de 2021 nunca se diligenciaba (faltante estructural): imputarlo inventaría un canal. Desde 2021 el faltante es esporádico.
clase_accidente	78 %	Categoría explícita SIN_DATO	Con la moda (CHOQUE) el 78 % pasaría a choque y se perdería la señal de atropellos y volcamientos.
vehiculo_mas_pesado	0,03 %	**Moda** (LIVIANO)	Solo 34 casos sin vehículo identificado tras KNN.
tipo_via / frecuencia_direccion	56 %	SIN_DATO / 0 + indicador tiene_direccion	Sin dirección no hay vía ni historial que contar.

4. Valores atípicos

- **num_vehiculos – Z-score:** el IQR es 0 (Q1 = Q3 = 2), por lo que la regla IQR marcaría como atípico todo lo que no sea 2. Con Z-score (media 1,96, desv. 0,44) $|z| > 3$ equivale a más de 3 vehículos: 930 casos (0,74 %). Son choques múltiples reales, así que **se conservan las filas y se acota el valor a 3** (winsorización). Se guarda la versión original para trazabilidad.
- **frecuencia_direccion – IQR:** límite 149,5 reportes; 7 254 siniestros (5,8 %) son atípicos. Son las intersecciones críticas, la información más valiosa: **se conservan** y se corrige el sesgo con logaritmo.

5. Transformaciones

- **log1p** en frecuencia_direccion: asimetría de 4,41 a 1,30 (incluye ceros, por eso log(1+x)).
- **Yeo-Johnson** ($\lambda = 1{,}63$, ajustado en train) en num_vehiculos acotado: asimetría de 1,01 a 0,24.
- **Codificación cíclica** del mes (seno y coseno) para que diciembre y enero queden cerca; variables de calendario (fin de semana, periodo COVID).

6. Codificación de categóricas

- **Ordinal Encoding** para variables con orden natural: la variable objetivo del P1 *gravedad_p1* (leve < grave < mortal), *vehiculo_mas_pesado* (BICICLETA < MOTO < LIVIANO < TRANSPORTE PÚBLICO < PESADO, por masa) y *franja_vehiculos* (1 < 2 < 3+). El orden tiene sentido físico y conserva la relación con la gravedad (98 % graves con bicicleta, 24 % con pesado).
- **One-Hot Encoding** con *pd.get_dummies(drop_first=True)* para variables nominales sin orden: clase_accidente, medio_reporte y tipo_via (3 variables → 20 columnas). drop_first evita la colinealidad perfecta (trampa de las dummies) en la regresión logística. No se usa ordinal en ellas porque «CAD 123» no es «mayor» que «RADIO».

7. Escalado (ajustado solo con train)

- **Min-Max [0,1]:** variables acotadas y sin outliers (año, día de la semana, mes seno/coseno, ordinales).
- **Z-score (StandardScaler):** log_frecuencia_direccion, aproximadamente simétrica tras el logaritmo.
- **RobustScaler** (mediana e IQR): conteos de vehículos con colas largas, para que los choques múltiples no dominen la escala.
- El parquet guarda las variables limpias **sin escalar**; en la Fase C el escalado se aplica dentro de un *Pipeline* que se ajusta en cada fold de entrenamiento, cumpliendo la regla de no normalizar antes del

split.