Fase C — Análisis de modelos y justificación del modelo final

Siniestralidad vial de Cali 2016–2024 · Grupo #5 · Juan Alejandro Urrego (2569068) · Mariana De Los Ángeles Viera (2569104) · Anderson Gómez (2266242) · Juan Esteban Martinez Orobio (2569452) · Profesor: Héctor Fabio Ocampo Arbeláez · Octubre 2026

Problema: **clasificación binaria** de es_grave (40,7 % graves). Se usa la partición 80/20 estratificada de la Fase B (99 911 / 24 978 filas, sin filas compartidas). Los hiperparámetros se eligen con validación cruzada estratificada de 3 folds **sobre train** optimizando F1; el escalado vive dentro del Pipeline; el test se evalúa una sola vez. 39 variables predictoras (se excluyen versiones redundantes que generaban colinealidad perfecta).

Tabla comparativa de métricas (conjunto de prueba)

Modelo	Acc.	Prec.	Recall	F1	AUC	F1 train	Brecha	Seg.
Random Forest	0.785	0.699	0.829	**0.758**	0.878	0.768	0.010	44
Árbol de Decisión	0.778	0.685	0.842	**0.755**	0.876	0.761	0.006	3
Regresión Logística	0.761	0.678	0.789	**0.729**	0.853	0.731	0.002	5
KNN	0.782	0.763	0.672	**0.715**	0.839	0.873	0.158	4

Línea base (predecir siempre «solo daños»): accuracy 0,593, recall y F1 = 0. Hiperparámetros elegidos: Regresión Logística C=10; Árbol max_depth=10, min_samples_leaf=20; Random Forest 150 árboles, max_depth=14, min_samples_leaf=5; KNN k=35 ponderado por distancia. Todos con class_weight=«balanced» salvo KNN.

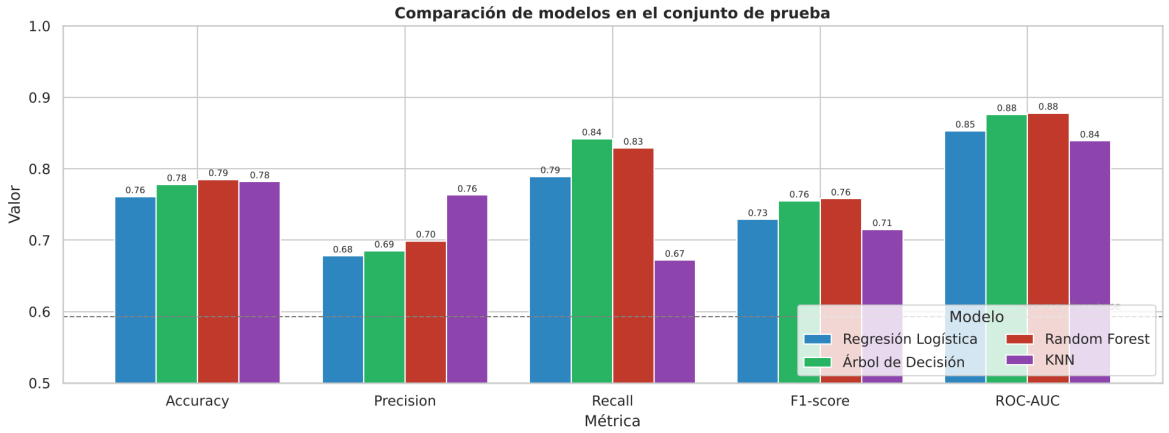


Figura 1. Comparación de métricas en test.

Análisis

- **Random Forest** logra el mejor F1 (0,758), accuracy (0,785) y ROC-AUC (0,878), con brecha train-test de 0,01: generaliza bien.
- **Árbol de Decisión** queda prácticamente empatado (F1 0,755; mayor recall, 0,842). Un bootstrap de 1 000 remuestreos del test da una diferencia de F1 RF − Árbol de 0,003 con IC 95 % [−0,0005; 0,0069]: **no es significativa**. Frente a la Regresión Logística (+0,029) y a KNN (+0,044) la ventaja de RF sí es significativa.
- **Regresión Logística** rinde menos porque el efecto de una variable depende de otras (la moto es grave sobre todo cuando no hay carro), algo que los árboles capturan y un modelo lineal no.
- **KNN** tiene la mejor precision (0,763) pero deja escapar un tercio de los graves (recall 0,672) y sobreajusta (F1 train 0,873 vs test 0,715).
- **Variables clave** (coinciden RF y Regresión Logística): número de vehículos livianos (protege), número de motos y bicicletas (aumentan gravedad), clase de accidente, vehículo más pesado y que

el reporte se haga desde una clínica (odds ×12).

- **Robustez temporal:** F1 entre 0,63 y 0,79 en 2016–2022; en 2023–2024 sube a 0,94–0,96 solo porque casi todo lo registrado es grave.

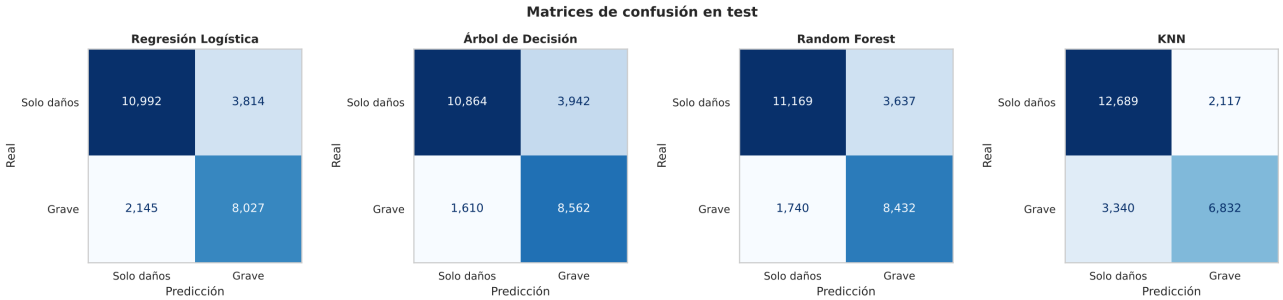


Figura 2. Matrices de confusión en test.

Objetivo del Proyecto 1: clasificación multiclase leve / grave / mortal

Modelo	Accuracy	F1 macro	Recall leve	Recall grave	Recall mortal	ROC-AUC (OvR)
Random Forest (multiclase)	0,743	**0,649**	0,719	0,781	0,722	0,887
Regresión Logística (multinomial)	0,721	0,604	0,729	0,707	0,749	0,861

Con la misma partición y el mismo preprocesamiento, el Random Forest multiclase detecta el 72 % de los siniestros mortales (≈463 de 641 en test), pero con precision de 0,32: dos de cada tres alertas de «mortal» no lo son (la mayoría son siniestros con lesionados). Sin velocidad, edad ni tipo de lesión, un siniestro grave y uno mortal se parecen mucho. Por eso la versión binaria es la principal (despacho) y la multiclase funciona como alerta temprana de posibles víctimas fatales.

Modelo no supervisado: K-Means sobre intersecciones (objetivo «segmentar barrios» del P1)

Como el CSV no trae barrio ni comuna, se segmenta la unidad geográfica más fina disponible. Se segmentan las 314 intersecciones con ≥ 20 siniestros según volumen (log), tasa de gravedad, % con moto y % con transporte público (Z-score). Con 7 variables la estructura era débil (Silhouette 0,16); quitar las variables casi constantes la mejoró a 0,28. **k = 4** maximiza Silhouette (0,279) y minimiza Davies-Bouldin (1,10); K-Means supera al jerárquico Ward (0,223 / 1,28). Segmentos: **corredores de transporte público** (33), **puntos de choques leves** (105), **puntos de motos y alta gravedad** (94; 58 % graves) y **puntos negros de alto volumen** (82; ≈71 siniestros cada uno).

Justificación del modelo final: Random Forest

- **Por precisión:** es el mejor en F1, accuracy y ROC-AUC, y supera significativamente a dos de los tres rivales.
- **Por estabilidad:** promedia 150 árboles, por lo que sus cortes no cambian bruscamente al agregar datos, y su brecha train-test es mínima.
- **Por utilidad operativa:** entrega probabilidades continuas que permiten fijar el umbral según el uso; con umbral 0,4 el recall sube a 0,89 (≈630 siniestros graves más detectados en test) manteniendo F1 0,756, lo recomendado para despacho de ambulancias.
- **Interpretabilidad:** se explica con importancia de variables, y como el Árbol de Decisión es estadísticamente equivalente, se usa como **modelo explicativo** para traducir el resultado en reglas de despacho («sin carro y con moto o bicicleta, o si es atropello o caída de ocupante → prioridad de ambulancia»).

- **Objetivo multiclase del P1:** también Random Forest (F1 macro 0,649 vs 0,604), como modelo complementario de alerta de víctimas fatales.