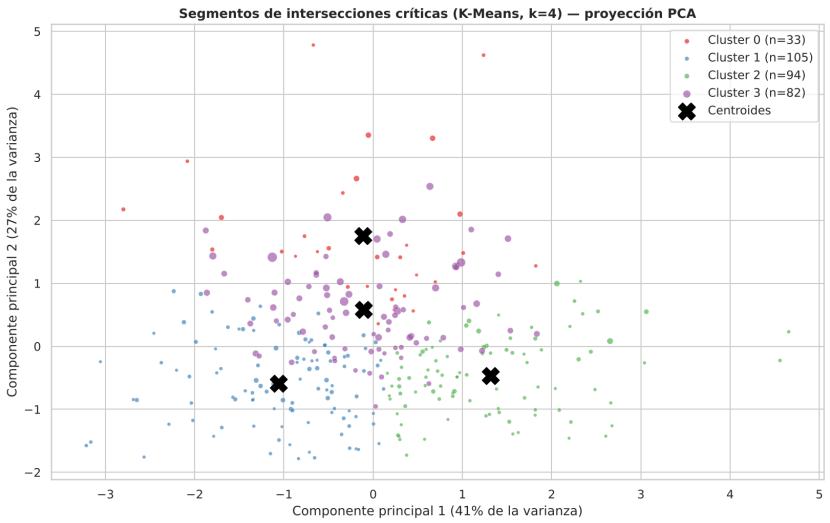
¿Será grave este siniestro?

Predicción de la gravedad de la siniestralidad vial en Santiago de Cali, 2016–2024



Informe final · Proyectos 2 y 3 (RA2 y RA3)
Introducción a la Ciencia de los Datos
Profesor: Héctor Fabio Ocampo Arbeláez

Grupo #5
Juan Alejandro Urrego (2569068)
Mariana De Los Ángeles Viera (2569104)
Anderson Gómez (2266242)
Juan Esteban Martinez Orobio (2569452)
Repositorio: github.com/alejoneru/Ciencia_De_Datos_
Octubre de 2026

Contenido: 1. Contexto, pregunta de negocio y continuidad con el Proyecto 1 · 2. Análisis exploratorio · 3. Limpieza y normalización · 4. Modelos y comparación · 5. Conclusiones y mejoras

Resumen

Se analizaron 371 003 reportes de incidentes viales de Cali. Tras limpiar y normalizar la información, se entrenaron cuatro clasificadores para predecir si un siniestro confirmado tendrá lesionados o fallecidos. **Random Forest** obtuvo el mejor desempeño en el conjunto de prueba (F1 = 0,758; ROC-AUC = 0,878; accuracy = 0,785), detectando el 83 % de los siniestros graves, y hasta el 89 % con un umbral ajustado al uso en despacho. Para el objetivo del Proyecto 1 (gravedad *leve / grave / mortal*), un Random Forest multiclase detecta el 72 % de los siniestros mortales. Un modelo K-Means segmentó las intersecciones críticas en cuatro tipos que requieren intervenciones distintas. Los principales determinantes de la gravedad son la presencia de motos o bicicletas y la ausencia de vehículos livianos.

1. Contexto del dataset, pregunta de negocio y continuidad con el Proyecto 1

El dataset (Secretaría de Movilidad de Santiago de Cali) registra los reportes de incidentes viales entre el 1 de enero de 2016 y noviembre de 2024: código, fecha, resultado confirmado (negativo, solo daños, con lesionado, con fallecido), dirección, clase de accidente, medio de reporte, número de vehículos y tipos de vehículos implicados. Es la continuación del Proyecto 1, en el que el grupo eligió este dataset y diseñó una bodega en modelo estrella.

Pregunta de negocio: ¿qué características conocidas al momento del reporte permiten anticipar si un siniestro será *grave* (con lesionados o fallecidos) frente a uno de *solo daños*? La respuesta sirve a dos usuarios: el **centro de despacho**, que decide si enviar ambulancia además de agentes de tránsito, y el **área de seguridad vial**, que decide dónde y hacia quién dirigir campañas e intervenciones de infraestructura.

Continuidad con el Proyecto 1. El diseño del P1 (FACT_SINIESTRO con cuatro dimensiones y la gravedad *leve / grave / mortal* como objetivo) se hizo con la ficha del catálogo y dejó validaciones pendientes. Al abrir el CSV real se encontraron diferencias (Tabla 1). El modelo estrella se reconstruyó con los datos reales, respetando las reglas del P1 (llaves subrogadas, registro −1 «Desconocido»), y adaptando lugar y actor. Los tres objetivos analíticos del P1 se cumplen así: *clasificar gravedad* con un modelo binario y otro multiclase; *segmentar barrios por riesgo* segmentando intersecciones, la unidad geográfica disponible; y *predecir por comuna-hora*, que no es posible sin comuna ni hora, se aborda con el riesgo por día de la semana y mes.

Diseño del Proyecto 1	CSV real	Adaptación en P2/P3
~90 000 registros	371 003 reportes; 124 889 siniestros confirmados	Se modelan los confirmados
Gravedad leve / grave / mortal	Solo daños / con lesionado / con fallecido	Equivalencia directa; modelo binario y multiclase
DIM_LUGAR: comuna, barrio, zona	Solo dirección en texto libre	Lugar = dirección normalizada; comuna y barrio «No disponible»
DIM_VIA: tipo, clase, superficie	No existen	tipo_via extraído de la dirección
DIM_ACTOR: actor, género, edad	Solo lista de vehículos	Perfil de vehículos (actor más vulnerable)
DIM_TIEMPO con posible hora	Solo fecha	Grano diario con los atributos del P1
Grano: un actor por fila	Una fila por siniestro	Grano siniestro; id_siniestro como degenerada

Tabla 1. Supuestos del diseño del Proyecto 1 frente al CSV real y su adaptación.

2. Resumen del análisis exploratorio

Del total de reportes, el 66 % resultó negativo; los 124 889 siniestros confirmados se dividen en 59 % solo daños, 38 % con lesionados y 2,7 % con fallecidos (3 360 casos). Los hallazgos clave fueron:

- **El actor vial define la gravedad** (Figura 1): 92 % de siniestros graves con bicicleta y 67 % con moto, frente a 17 % cuando solo hay carros. La presencia de motos es la variable con mayor correlación positiva con la gravedad (Spearman +0,49) y el número de vehículos livianos la de mayor correlación negativa (−0,53). Pearson y Spearman coinciden, por lo que las relaciones son monótonas.
- **Cambio de registro** (Figura 2): los siniestros graves bajan gradualmente, pero los de solo daños casi desaparecen desde finales de 2022, y la clase de accidente y el medio de reporte solo se diligencian sistemáticamente desde 2021.
- **Dónde y cuándo:** el domingo tiene la mayor proporción de graves (50 %) y el 10 % de las intersecciones concentra el 46 % de los siniestros graves con dirección.
- **Consulta sobre el modelo estrella del P1:** los siniestros *mortales* son estables (362–451 por año entre 2016 y 2023) mientras los leves se desploman; el % mortal pasa de ≈2 % a 7,9 %. Los mortales son la serie más confiable para comparar años, y no muestran mejora.

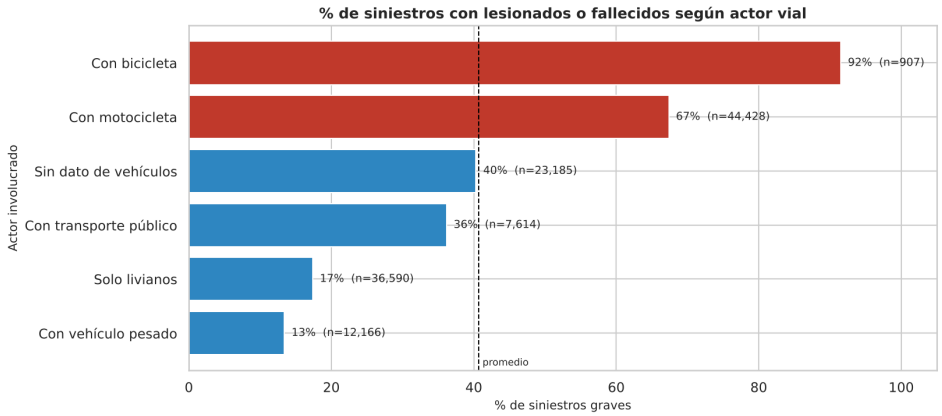


Figura 1. Proporción de siniestros graves según el actor vial involucrado.

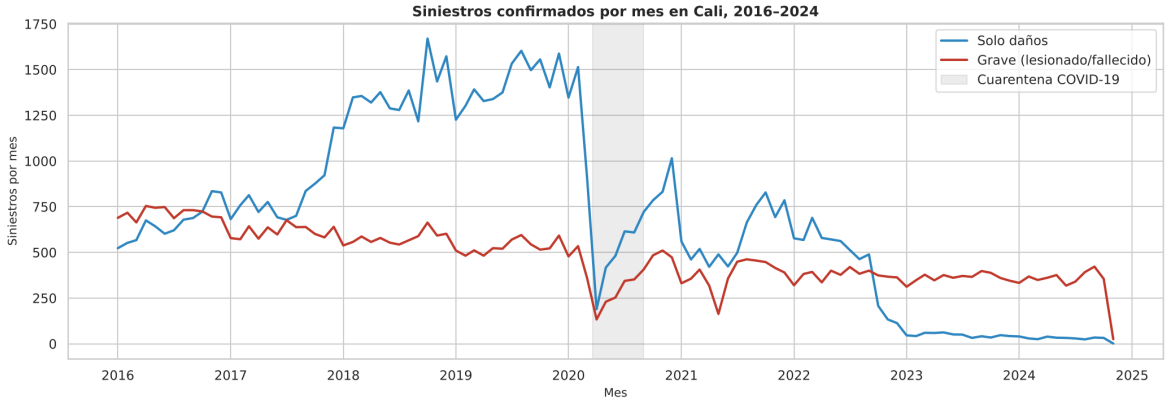


Figura 2. Siniestros confirmados por mes según gravedad (sombreado: cuarentena COVID-19).

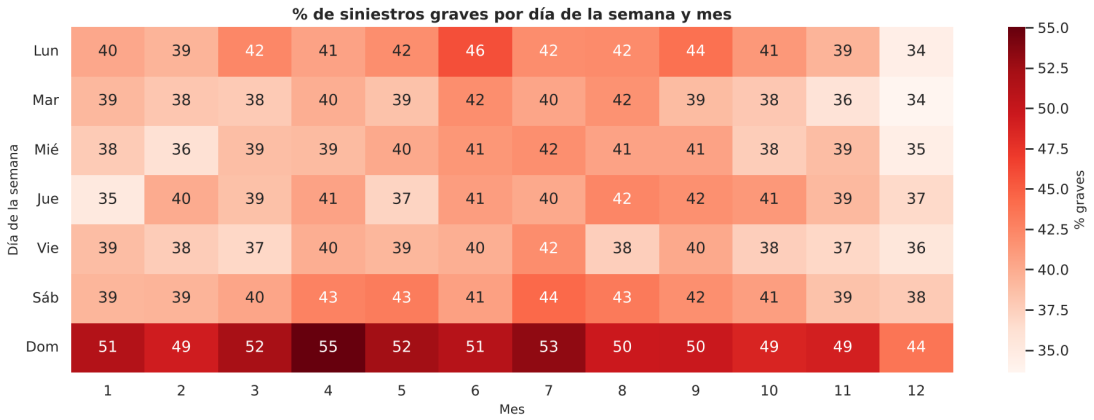


Figura 3. Porcentaje de siniestros graves por día de la semana y mes.

3. Técnicas de limpieza y normalización

La limpieza (detallada en *fase_b_limpieza.ipynb* y *fase_b_justificacion.pdf*) siguió once pasos. Primero, el diagnóstico reveló que la base usa «.» como valor vacío, 4 duplicados exactos, una columna duplicada, categorías escritas de varias formas y caracteres corruptos. Se eliminaron los duplicados, la columna repetida y **detalle_confirmado, por fuga de información** (se redacta después de conocer la gravedad). Luego se construyeron variables: calendario (año, día, fin de semana, mes cíclico, periodo COVID), conteos por familia de vehículo, vehículo más pesado, indicadores de dirección y clínica, y la frecuencia histórica de reportes en cada dirección.

Para evitar fuga de información, **la partición estratificada 80/20 se hizo antes de imputar y escalar**, y todos los parámetros se ajustaron solo con train. Las decisiones principales se resumen en la Tabla 2. Este proceso cumple el papel del ETL previsto en el P1 y resuelve sus validaciones pendientes (codificación cp1252, «.» como nulo, ausencia de hora, regla de desduplicación por id_siniestro).

Tarea	Técnica aplicada	Justificación
Nulos	Mediana (num_vehiculos), KNN k=5 (conteos por tipo de vehículo), moda por año (medio de reporte 2021–24, vehículo más pesado), categoría SIN_DATO (faltantes estructurales) e indicadores de faltante	Según el tipo de variable y el mecanismo del faltante: no inventar categorías donde el campo nunca se registró
Outliers	Z-score en num_vehiculos (0,74 %, acotar a 3); IQR en frecuencia por dirección (5,8 %, conservar)	El IQR de num_vehiculos es 0; los atípicos son eventos reales y puntos críticos
Sesgo	log1p (asimetría 4,41 → 1,30) y Yeo-Johnson (1,01 → 0,24)	Favorece modelos lineales y basados en distancia
Encoding	Ordinal: gravedad del P1 (leve < grave < mortal), vehículo más pesado y franja de vehículos. One-Hot drop_first=True: clase de accidente, medio de reporte, tipo de vía	Orden natural (masa, cantidad) vs. categorías nominales
Escalado	Min-Max (acotadas), Z-score (log frecuencia), RobustScaler (conteos)	Según la forma de cada variable; ajustado en train dentro del Pipeline

Tabla 2. Resumen de las técnicas de limpieza y normalización.

El resultado, *datos_limpios.parquet*, tiene 124 889 filas y 54 columnas sin nulos, con la partición guardada para que la Fase C use exactamente las mismas filas.

4. Modelos entrenados y comparación de desempeño

Se entrenaron cuatro clasificadores supervisados — Regresión Logística, Árbol de Decisión, Random Forest y KNN — cada uno dentro de un Pipeline (escalado + modelo) con búsqueda de hiperparámetros por validación cruzada estratificada de 3 folds sobre train, optimizando F1 de la clase grave y con pesos balanceados. La evaluación se hizo una sola vez sobre el 20 % de prueba (Tabla 3).

Modelo	Acc.	Prec.	Recall	F1	AUC	F1 train	Brecha	Seg.
Random Forest	0.785	0.699	0.829	**0.758**	0.878	0.768	0.010	44
Árbol de Decisión	0.778	0.685	0.842	**0.755**	0.876	0.761	0.006	3
Regresión Logística	0.761	0.678	0.789	**0.729**	0.853	0.731	0.002	5
KNN	0.782	0.763	0.672	**0.715**	0.839	0.873	0.158	4

Tabla 3. Métricas en el conjunto de prueba (línea base que predice siempre «solo daños»: accuracy 0,593, F1 0).

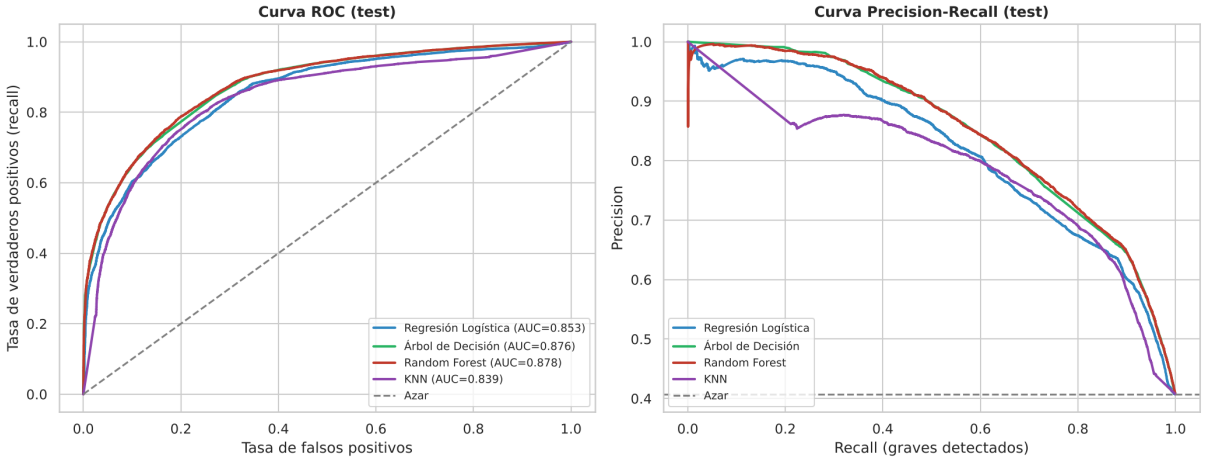


Figura 4. Curvas ROC y Precision-Recall de los cuatro modelos en test.

Random Forest y el Árbol de Decisión dominan en todo el rango de la curva ROC (AUC ≈ 0,88). Un bootstrap de 1 000 remuestreos confirma que la ventaja de Random Forest sobre la Regresión Logística (+0,029 de F1) y KNN (+0,044) es significativa, mientras que frente al Árbol (+0,003) no lo es. KNN muestra sobreajuste (brecha de 0,16) y bajo recall.

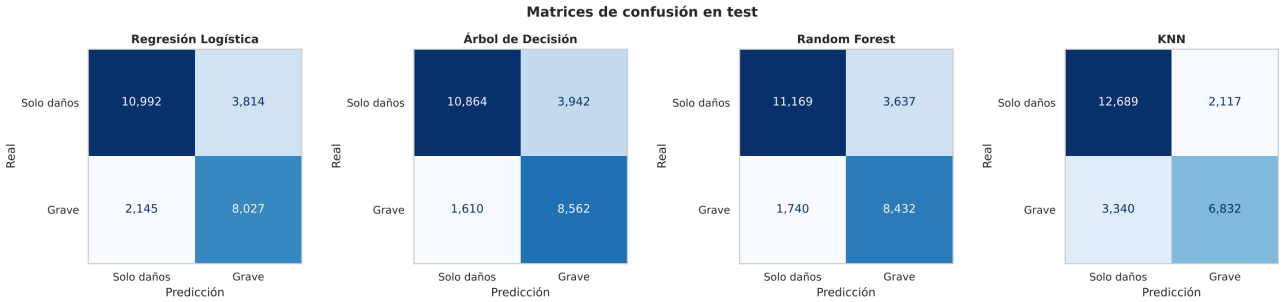


Figura 5. Matrices de confusión en test.

¿Qué aprendió el modelo? Las variables más importantes en Random Forest son el número de vehículos livianos y de motos, la clase de accidente, el año, el vehículo más pesado y el número de vehículos. La Regresión Logística coincide: una bicicleta o un reporte desde clínica multiplican las *odds* de gravedad por más de 10, y una moto por ≈2,6. El primer corte del Árbol separa los siniestros con a lo sumo un carro (mayoría graves) de los que tienen dos o más (≈85 % solo daños).

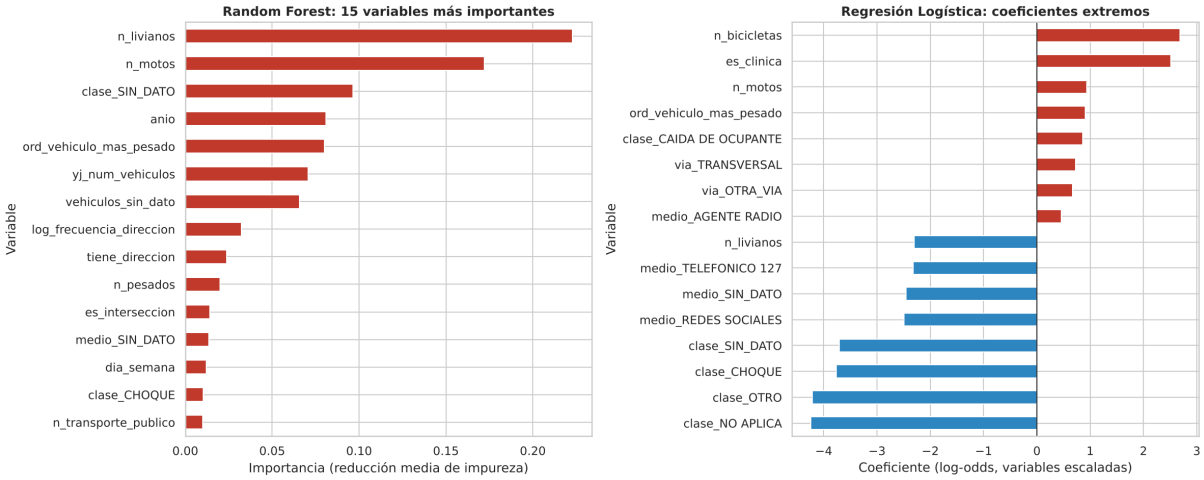


Figura 6. Importancia de variables (Random Forest) y coeficientes extremos (Regresión Logística).

Umbral de decisión y robustez. Mover el umbral cambia el equilibrio entre detectar graves y enviar recursos de más (Tabla 4). Por año, el F1 del modelo final se mantiene entre 0,63 y 0,79 en 2016–2022; en 2023–2024 sube a 0,94–0,96 solo porque casi todo lo registrado es grave, por lo que esas cifras no deben leerse como mejora del modelo.

Umbral	Precisio n	Recall	F1	% de siniestros alertados	Uso sugerido
0,3	0,637	0,906	0,748	58 %	Máxima cobertura
0,4	0,657	**0,891**	0,756	55 %	**Despacho de ambulancias**
0,5	0,699	0,829	0,758	48 %	Equilibrio (por defecto)
0,6	0,803	0,675	0,734	34 %	Recursos limitados
0,7	0,858	0,569	0,684	27 %	Campañas focalizadas

Tabla 4. Efecto del umbral de decisión en el Random Forest (conjunto de prueba).

Modelo final: Random Forest, por ser el más preciso en F1, accuracy y AUC, por su estabilidad (brecha train-test 0,01) y porque sus probabilidades continuas permiten ajustar el umbral al uso. Con umbral 0,4, recomendado para despacho, el recall sube de 0,83 a 0,89 manteniendo un F1 de 0,756. El Árbol de Decisión, estadísticamente equivalente, se adopta como modelo explicativo para comunicar reglas sencillas al personal de despacho.

Objetivo del Proyecto 1: gravedad leve / grave / mortal. Con la misma partición y el mismo preprocesamiento se entrenaron dos modelos multiclase. El Random Forest obtuvo accuracy 0,743, F1 macro 0,649 y ROC-AUC 0,887, frente a F1 macro 0,604 de la Regresión Logística multinomial. Detecta el 72 % de los siniestros mortales, aunque con precision de 0,32; cuando falla con un mortal, lo confunde sobre todo con grave (Figura 7). Sin velocidad, edad ni tipo de lesión, ambos niveles se parecen mucho. Por eso el modelo binario es el principal para despacho, y el multiclase sirve como alerta temprana de posibles víctimas fatales.

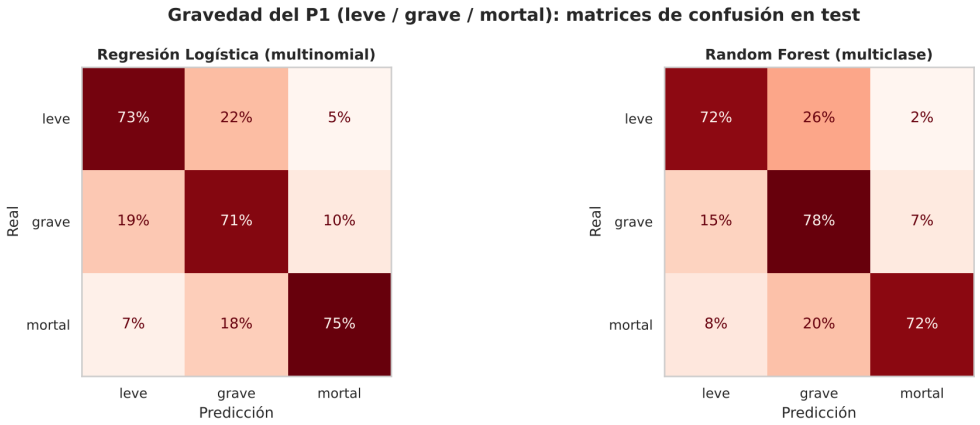


Figura 7. Matrices de confusión normalizadas del modelo multiclase (leve / grave / mortal).

Segmentación no supervisada (objetivo «segmentar barrios» del P1). Como el CSV no trae barrio, se segmentó la intersección. K-Means agrupó las 314 intersecciones con al menos 20 siniestros. k = 4 fue elegido porque maximiza el Silhouette (0,279) y minimiza Davies-Bouldin (1,10), superando al clustering jerárquico (0,223 / 1,28). Los cuatro tipos (Figura 8) son: **corredores de transporte público** (33 intersecciones, 27 % de siniestros con bus), **puntos de choques leves** (105, 35 % graves), **puntos de motos y alta gravedad** (94, 68 % con moto y 58 % graves) y **puntos negros de alto volumen** (82, ≈71 siniestros cada uno). Cada tipo pide una intervención distinta: carriles y control del SITM, semaforización, control de velocidad y campañas para motociclistas, y rediseño vial prioritario, respectivamente.

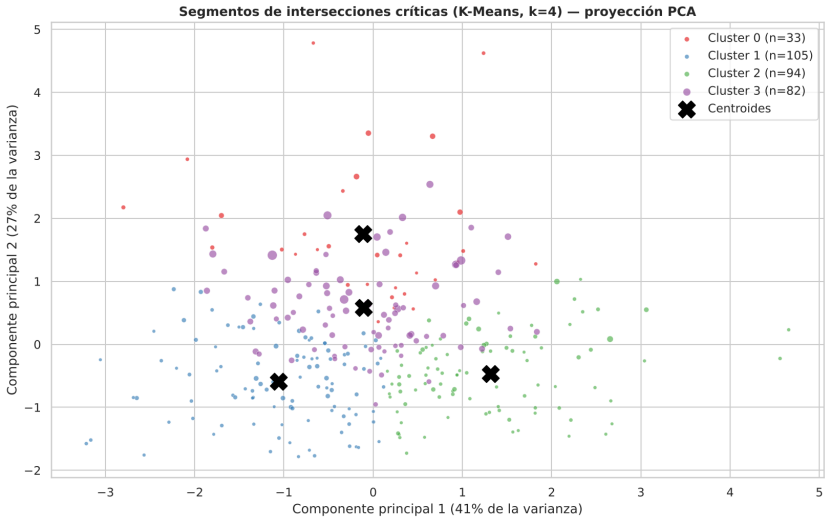


Figura 8. Segmentos de intersecciones (K-Means k=4) proyectados con PCA; el tamaño indica el número de siniestros.

5. Conclusiones y posibles mejoras

Conclusiones

- Es posible anticipar la gravedad de un siniestro con la información del reporte: el modelo final identifica correctamente 8 de cada 10 siniestros graves (9 de cada 10 con umbral 0,4) y ordena correctamente el riesgo el 88 % de las veces (AUC).
- La gravedad la definen sobre todo los **actores vulnerables** (moto, bicicleta, peatón atropellado) y la ausencia de carros: las campañas y la prioridad de despacho deben centrarse en ellos.
- La limpieza fue determinante: tratar los «.» como nulos, eliminar la columna con fuga y respetar los faltantes estructurales evitó modelos engañosamente buenos.

- La calidad del registro cambió en 2022–2024: los indicadores recientes no son comparables con los históricos y el modelo debe recalibrarse con datos nuevos.
- La segmentación de intersecciones convierte el análisis en una lista priorizada de puntos y tipos de intervención.
- Hay continuidad con el Proyecto 1: el modelo estrella diseñado funciona con los datos reales tras adaptarlo, y sus tres objetivos analíticos quedaron atendidos con las limitaciones documentadas de la fuente.

Posibles mejoras

- **Más datos:** integrar las otras dos fuentes evaluadas en el P1 (*Lesionados* y *Muertes en accidentes de tránsito*), primero como validación externa de los totales anuales y luego para aportar actor vial, género y edad; hora del siniestro, coordenadas geográficas, condiciones climáticas, tipo de vía y límite de velocidad, edad y rol de las víctimas; cruzar con datos de tráfico para obtener tasas por volumen vehicular.
- **Más features:** geocodificar direcciones para clustering espacial (DBSCAN sobre coordenadas), festivos y eventos, historial de gravedad por punto calculado solo con datos pasados.
- **Hiperparámetros:** búsquedas más amplias (RandomizedSearch u Optuna) con 5 folds, y calibración de probabilidades.
- **Otros algoritmos:** Gradient Boosting (XGBoost, LightGBM), sobremuestreo (SMOTE) para mejorar la precision de la clase mortal y modelos que ponderen el costo distinto de cada error.
- **Validación temporal:** entrenar con años anteriores y probar con posteriores para simular el uso real y vigilar la deriva del registro.