¿Será grave este siniestro?

Predicción de la gravedad de la siniestralidad vial en Cali, 2016–2024

Proyectos 2 y 3 (RA2 y RA3) · Introducción a la Ciencia de los Datos

Profesor: Héctor Fabio Ocampo Arbeláez

Grupo #5: Juan Alejandro Urrego · Mariana De Los Ángeles Viera

Anderson Gómez · Juan Esteban Martinez Orobio

Octubre de 2026

Contexto y pregunta de negocio

371 003
reportes de incidentes viales 2016–2024

66 %
de los reportes no eran siniestros (negativos)

124 889
siniestros confirmados

41 %
con lesionados o fallecidos (3 360 con fallecidos)

Pregunta: con la información disponible al recibir el reporte (fecha, lugar, vehículos, clase de accidente, canal), **¿podemos anticipar si el siniestro tendrá lesionados o fallecidos?**

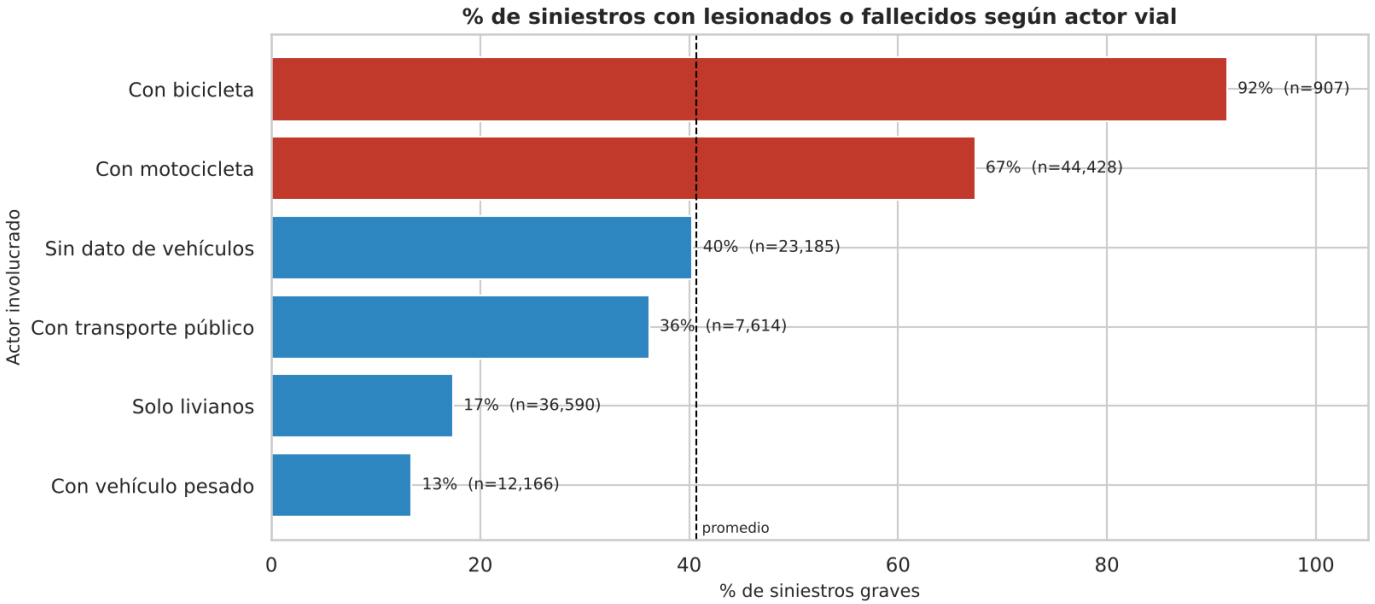
- **Centro de despacho:** decidir si enviar ambulancia además de agentes de tránsito.
- **Seguridad vial:** saber hacia qué actores y qué intersecciones dirigir campañas e intervenciones.
- Continuación del Proyecto 1: mismo dataset (Secretaría de Movilidad de Cali), ahora limpio y modelado.

Continuidad con el Proyecto 1

Diseño del P1	CSV real	Adaptación
Gravedad leve / grave / mortal	Solo daños / lesionado / fallecido	Equivalencia directa; modelo binario + multiclase
DIM_LUGAR: comuna, barrio	Solo dirección en texto	Lugar = dirección; segmentación de intersecciones
DIM_VIA: tipo, clase, superficie	No existen	tipo_via extraído de la dirección
DIM_ACTOR: actor, género, edad	Solo lista de vehículos	Perfil de vehículos (actor más vulnerable)
DIM_TIEMPO con hora	Solo fecha	Grano diario, mismos atributos
~90 000 registros, grano actor	371 003 reportes, grano siniestro	124 889 siniestros confirmados

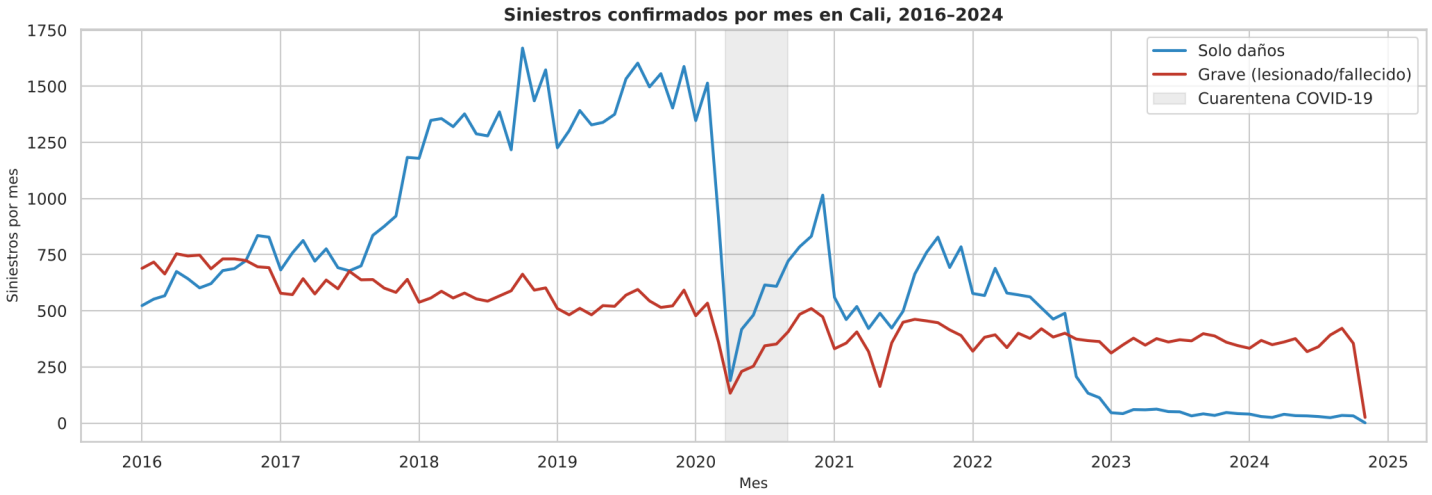
- El **modelo estrella del P1** se reconstruyó con los datos reales (llaves subrogadas, registro −1 «Desconocido»): 124 890 hechos, 3 227 fechas, 23 490 lugares.
- Objetivos del P1: **clasificar gravedad** → binario y multiclase · **segmentar barrios** → intersecciones · **comuna-hora** → día y mes (no hay hora).
- Consulta sobre la estrella: los siniestros **mortales son estables** (362–451 al año): no hay mejora en muertes.

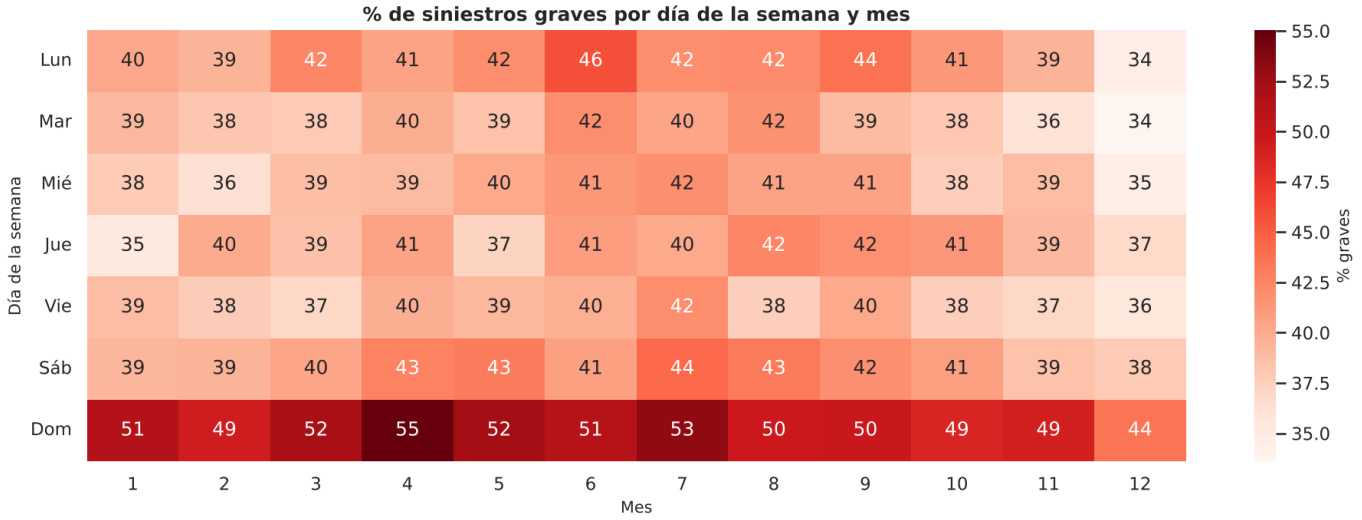
Hallazgo 1: el actor vial define la gravedad



- Con **bicicleta**, el 92 % de los siniestros es grave; con **moto**, el 67 %.
- Entre **solo carros**, apenas el 17 %.
- Correlación de Spearman con la gravedad: motos **+0,49**, vehículos livianos **−0,53**.
- Siniestros de 1 vehículo: 21 % de los graves vs 3 % de los de solo daños.

Hallazgos 2 y 3: el registro cambió y el domingo pesa más





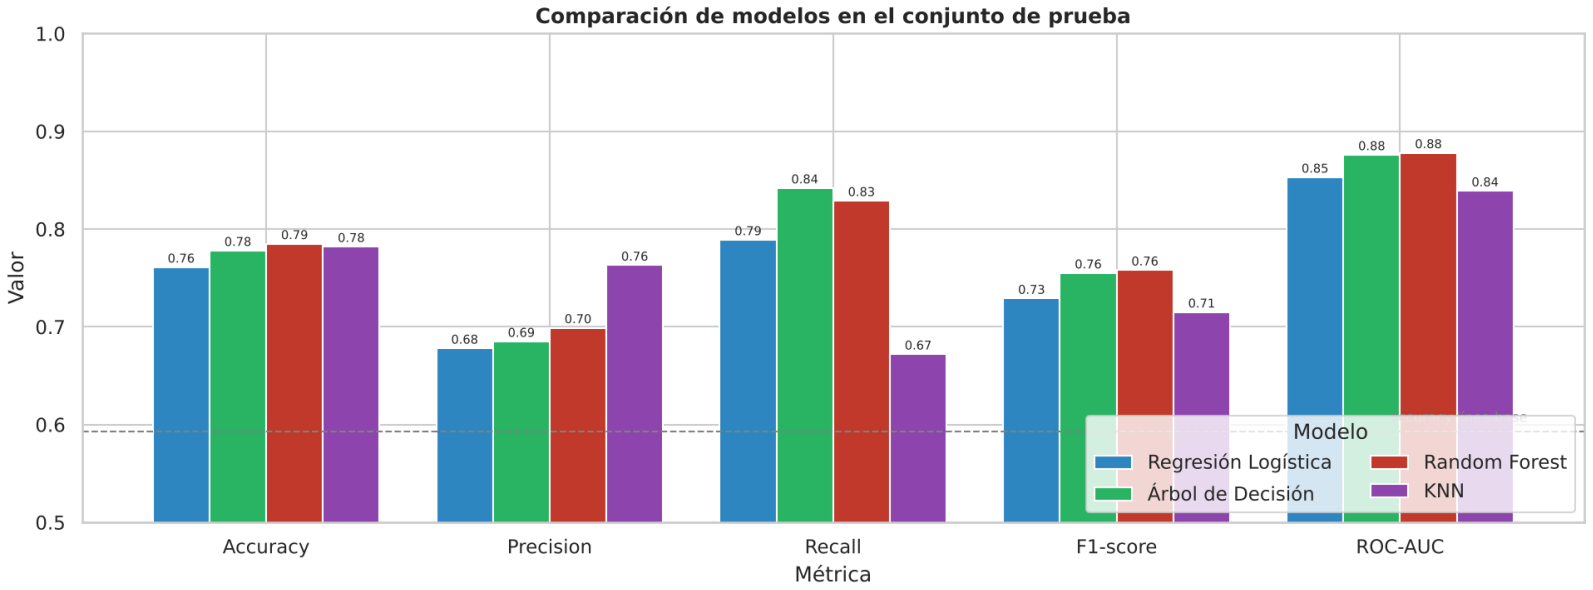
- Los graves bajan gradualmente (≈700 → ≈370 al mes).
- Los de **solo daños casi desaparecen desde finales de 2022**: cambio de protocolo, no mejora real.
- Clase de accidente y medio de reporte vacíos en el 78 %: solo se registran bien desde 2021.
- **Domingo:** 50 % de graves vs ≈39 % entre semana.
- 10 % de las intersecciones concentra el **46 %** de los siniestros graves.

Limpieza y normalización

Problema	Decisión
«.» usado como vacío; 4 duplicados; columna repetida	Convertir a nulo; eliminar duplicados y copia
detalle_confirmado se escribe tras conocer la gravedad	Eliminar: fuga de información
Textos inconsistentes (CHOQUE/Choque, TELEF?NICO…)	Normalizar, unificar sinónimos, raras → OTRO
Nulos	Mediana · KNN (k=5) · moda por año · SIN_DATO + indicadores
Outliers	Z-score (num_vehiculos, IQR = 0) → acotar · IQR (puntos críticos) → conservar
Variables sesgadas	log1p (asimetría 4,4 → 1,3) · Yeo-Johnson (1,0 → 0,2)
Categóricas	Ordinal (vehículo más pesado, franja) · One-Hot drop_first (clase, medio, vía)
Escalado	Min-Max · Z-score · RobustScaler, ajustados solo en train

Anti-fuga: la partición 80/20 estratificada se hizo **antes** de imputar y escalar. Resultado: datos_limpios.parquet, 124 889 filas × 54 columnas, 0 nulos.

Cuatro modelos supervisados, evaluados en test

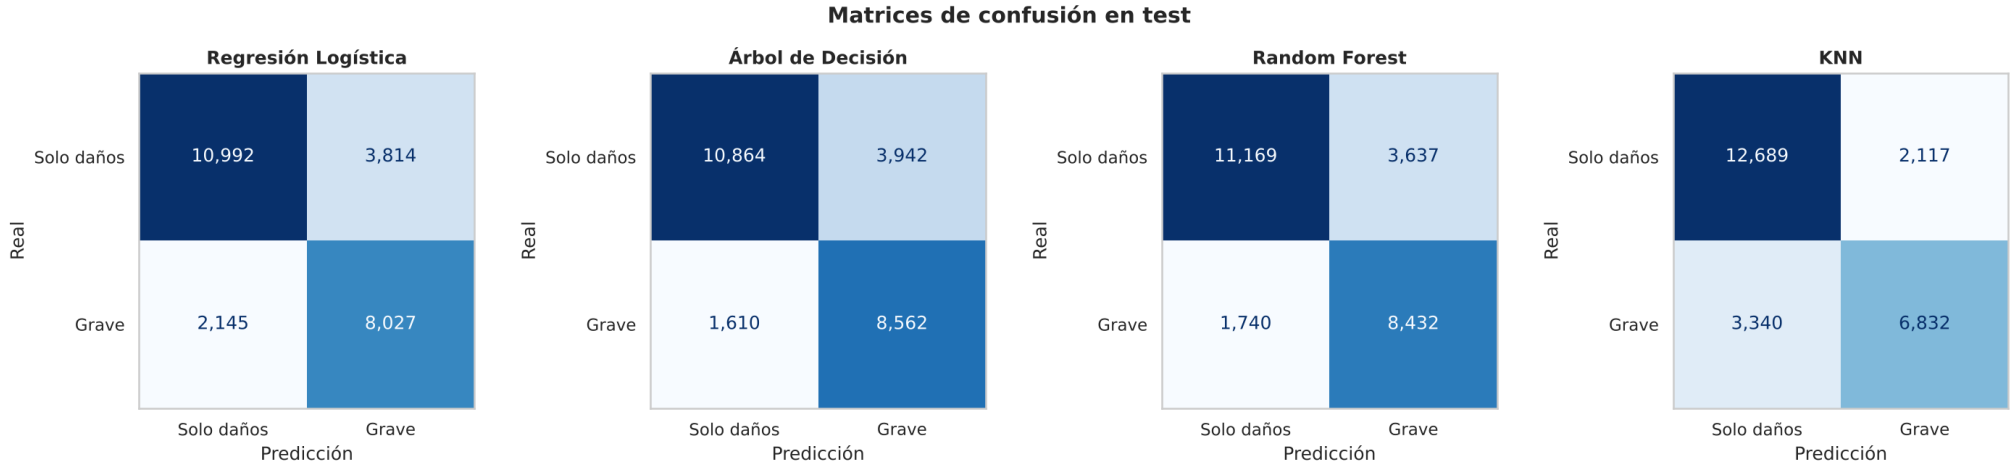


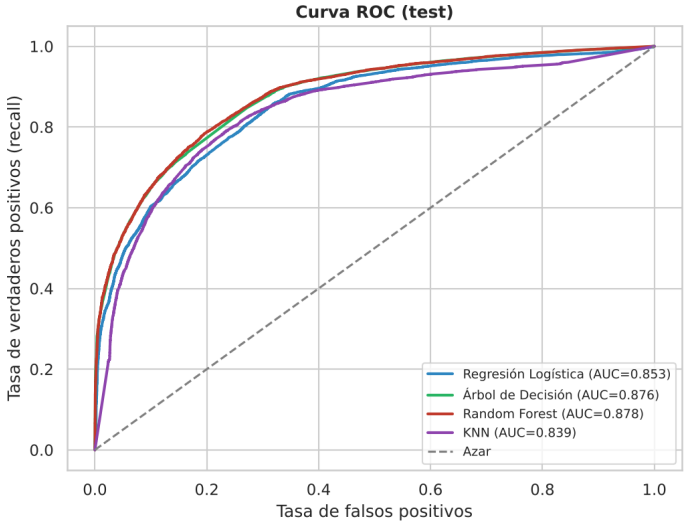
Modelo	F1	AUC	Recall
Random Forest	0.758	0.878	0.829
Árbol de Decisión	0.755	0.876	0.842
Regresión Logística	0.729	0.853	0.789
KNN	0.715	0.839	0.672

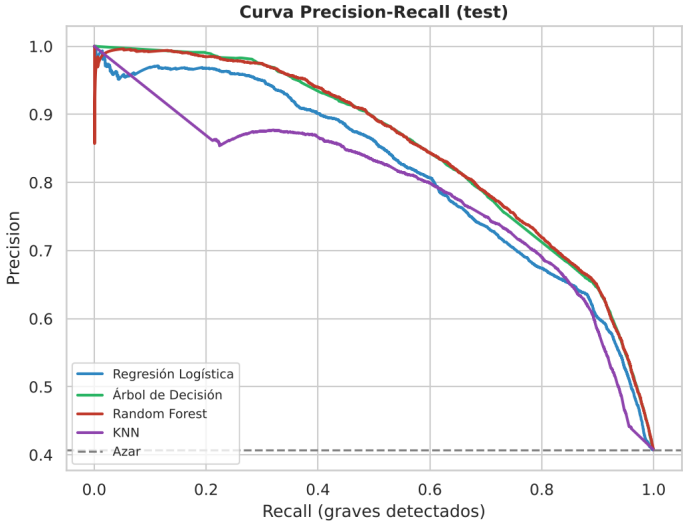
- Pipeline (escalado + modelo), CV 3 folds en train, F1 como criterio.
- Línea base: accuracy 0,593, F1 = 0.
- KNN sobreajusta: F1 train 0,87 vs test 0,72.

- **Random Forest** gana en F1, accuracy y AUC; el Árbol queda estadísticamente empatado (bootstrap IC 95 % de la diferencia incluye 0).

¿Cuántos siniestros graves detectamos?

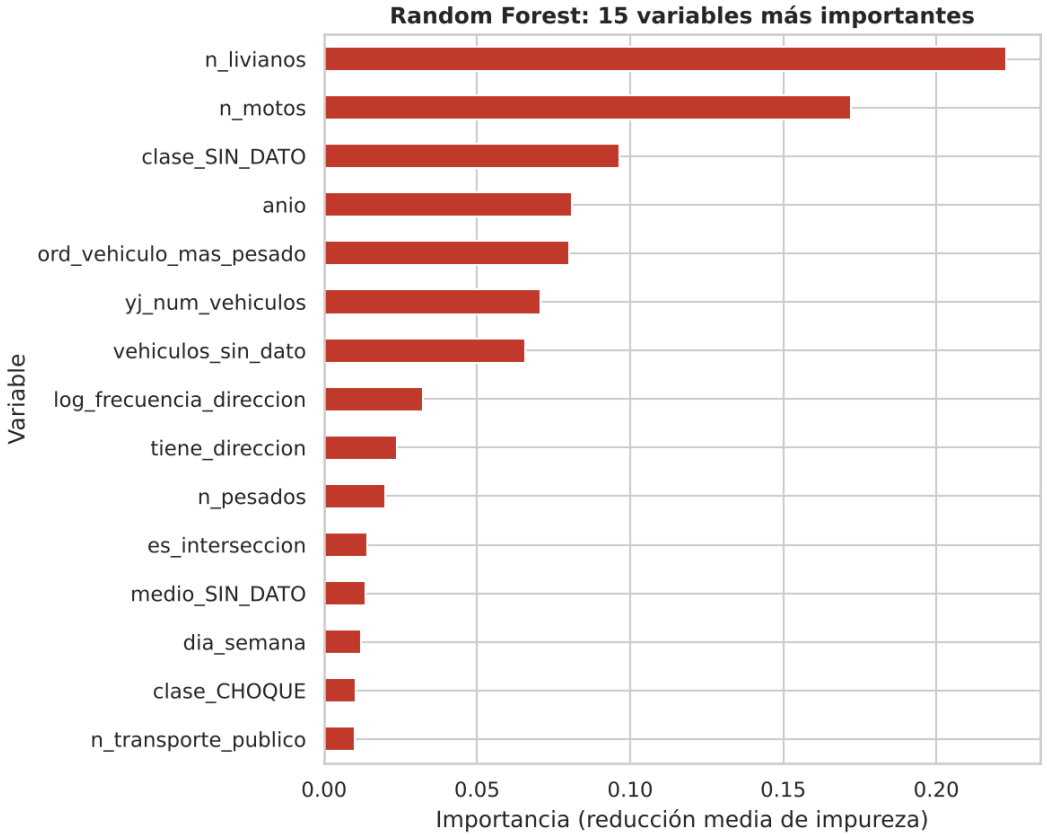


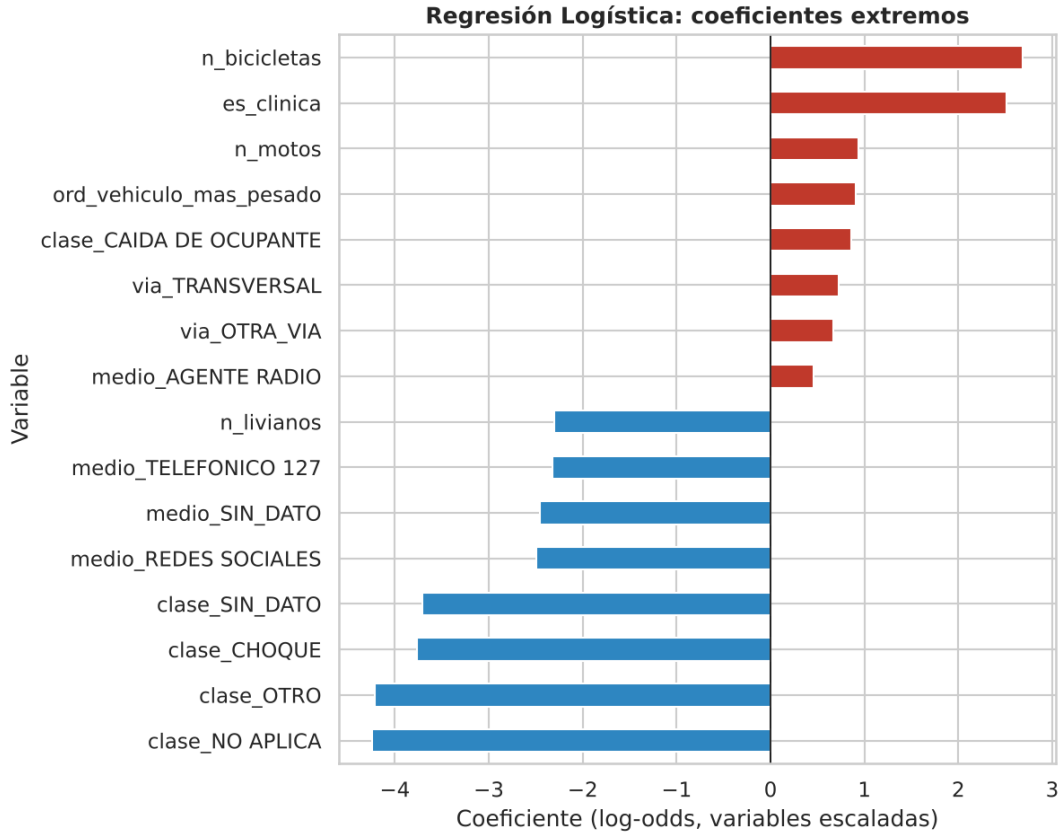




- Random Forest detecta **8 433 de 10 172** graves en test (83 %).
- AUC 0,878: ordena correctamente el riesgo el 88 % de las veces.
- Costo: ≈3 600 siniestros leves marcados como graves; preferible a no enviar ambulancia.

¿Qué aprendieron los modelos?





- Más **carros** → menos gravedad; **motos y bicicletas** → más gravedad (bicicleta: odds ×15; moto: ×2,6).
- Reporte desde **clínica**: odds ×12. Clase **choque** mucho menos grave que atropello.
- Regla del árbol: a lo sumo un carro + atropello/caída/volcamiento → ≈96 % grave.

Modelo final: Random Forest

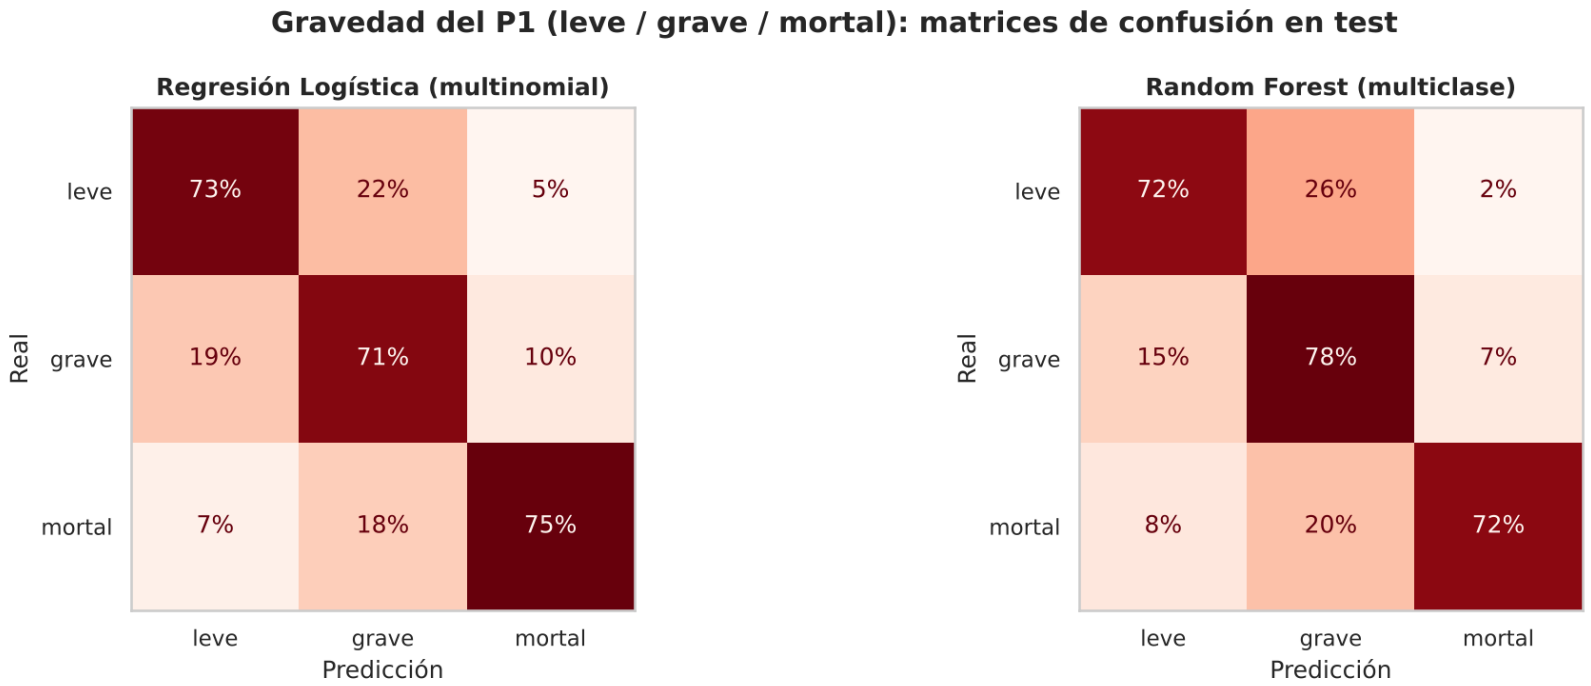
- **Precisión:** mejor F1 (0,758), accuracy (0,785) y AUC (0,878).
- **Estabilidad:** brecha train-test 0,01; promedia 150 árboles.
- **Utilidad:** probabilidades continuas → umbral según el uso.
- **Interpretabilidad:** importancia de variables + Árbol de Decisión (equivalente) como modelo explicativo.

Umbral	Precision	Recall	Uso
0,3	0,64	0,91	Máxima cobertura
0,4	0,66	0,89	Despacho de ambulancias
0,5	0,70	0,83	Equilibrio
0,7	0,86	0,57	Campañas focalizadas

Con umbral **0,4** el recall sube a **0,89**: ≈630 siniestros graves más detectados en test, con el mismo F1.

- Descartados: Regresión Logística (no capta interacciones) y KNN (recall 0,67, sobreajuste).

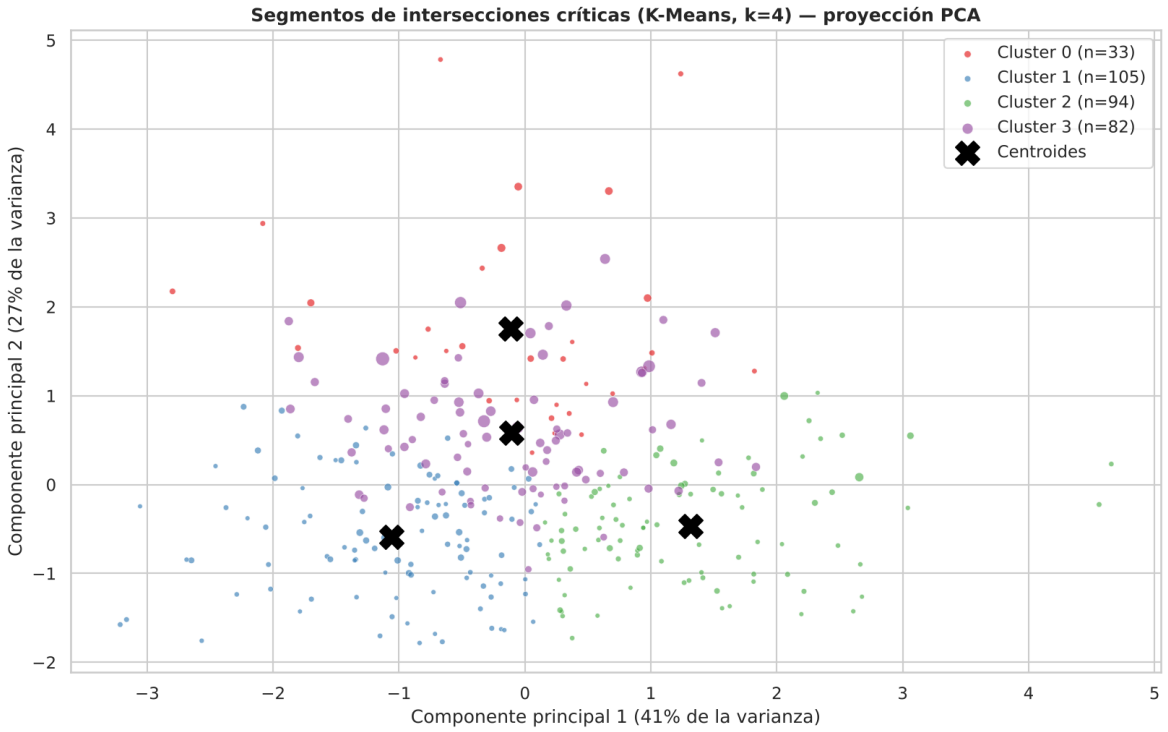
Objetivo del P1: leve / grave / mortal



Modelo	F1 macro	Recall mortal	AUC
Random Forest	0,649	0,722	0,887
Reg. Logística	0,604	0,749	0,861

- Detecta el **72 % de los mortales** (≈463 de 641 en test).
- Precision mortal 0,32: sin velocidad, edad ni lesión, grave y mortal se parecen.
- Uso: **alerta temprana** de posibles víctimas fatales; el binario sigue siendo el principal.

Segmentación de intersecciones con K-Means



Segmento	Perfil	Acción
Corredores de transporte público (33)	27 % con bus; 53 % graves	Control SITM, paraderos
Choques leves (105)	35 % graves	Semaforización, señales
Motos y alta gravedad (94)	68 % con moto; 58 % graves	Velocidad, cámaras, campañas
Puntos negros de alto volumen (82)	≈71 siniestros c/u	Rediseño vial prioritario

- 314 intersecciones con ≥ 20 siniestros; 4 variables (volumen, gravedad, % moto, % bus).
- k = 4: mejor Silhouette (0,279) y Davies-Bouldin (1,10); supera al jerárquico Ward (0,223).

Conclusiones

- Sí es posible anticipar la gravedad desde el reporte: **8–9 de cada 10 siniestros graves detectados**.
- La gravedad la definen los **actores vulnerables** (moto, bicicleta, peatón) y la ausencia de carros.
- La limpieza fue clave: «.» como nulo, eliminar la columna con fuga, respetar los faltantes estructurales.
- El registro de 2023–2024 no es comparable con el histórico: el modelo debe recalibrarse.
- La segmentación convierte el análisis en una lista priorizada de intersecciones e intervenciones.
- Continuidad: el modelo estrella del P1 funciona con los datos reales y sus 3 objetivos quedaron atendidos.

Posibles mejoras y próximos pasos

- **Más datos:** integrar Lesionados y Muertes (fuentes evaluadas en el P1) para validar y aportar género y edad; hora, coordenadas, clima, límite de velocidad, edad y rol de las víctimas, volumen de tráfico.
- **Más features:** geocodificación y DBSCAN espacial, festivos y eventos, historial de gravedad por punto (solo pasado).
- **Hiperparámetros:** búsqueda más amplia (Optuna), 5 folds, calibración de probabilidades.
- **Otros algoritmos:** XGBoost / LightGBM, SMOTE para la clase mortal, aprendizaje sensible al costo.
- **Validación temporal:** entrenar con el pasado y probar con el futuro para vigilar la deriva del registro.

¡Gracias! ¿Preguntas?